

Módulo 4: Aprendizaje Automático

Clase 4: Regresión Logística y Clasificación Binaria

Diplomado en Ciencia de Datos

8 de julio de 2026


Objetivos de la Sesión

- Comprender la diferencia entre predecir valores continuos (Regresión) y valores discretos (Clasificación).
- Analizar las limitaciones de la Regresión Lineal para problemas de decisión binaria.
- Introducir la **Función Sigmoide** y el concepto de probabilidad y umbral (Threshold).
- Evaluar el rendimiento de un modelo de clasificación utilizando la Matriz de Confusión y métricas de negocio (Precisión y Recall).

¿Por qué no usar simplemente una recta $y = mx + b$?

- La regresión lineal puede predecir valores negativos o mayores que 1.
- Para la clasificación binaria, interpretamos el resultado como una **probabilidad**, que debe estar en el rango $[0, 1]$.

El Problema de la Regresión Lineal (Visualización)



Fundamento Matemático:


Pasamos el resultado de nuestra recta a través de la **Función Sigmoide**:

$$P(y = 1|X) = \frac{1}{1 + e^{-z}}$$

Donde $z = \beta_0 + \beta_1 x_1 + \dots + \beta_n x_n$.

- **Umbral (Threshold):** Usualmente, si $P \geq 0,5$, predecimos 1. Si $P < 0,5$, predecimos 0.

La Función Sigmoide (Visualización)



Separación en el Espacio Dimensional

- La Regresión Logística crea un **Hiperplano** (una línea en 2D, un plano en 3D) que corta el espacio.
- Este corte ocurre exactamente donde la probabilidad es del 50 % ($P = 0,5$).
- Separa las instancias clasificadas como positivas de las clasificadas como negativas.

Evaluación: Matriz de Confusión

En clasificación, la exactitud (Accuracy) es insuficiente.

Real \ Predicción	Predice Negativo (0)	Predice Positivo (1)
Es Negativo (0)	Verdadero Negativo (VN)	Falso Positivo (FP)
Es Positivo (1)	Falso Negativo (FN)	Verdadero Positivo (VP)

- **FP (Error Tipo I):** El modelo predice 1, pero era 0.
- **FN (Error Tipo II):** El modelo predice 0, pero era 1.

Métricas de Negocio: Precisión vs Recall

Dependiendo del objetivo del negocio, se prioriza una u otra:

- **Precisión ($VP/(VP + FP)$):** Calidad. De todos los positivos predichos, ¿cuántos lo son realmente?
 - *Ideal cuando un FP es costoso.*
- **Sensibilidad o Recall ($VP/(VP + FN)$):** Cantidad. De todos los positivos reales, ¿cuántos logró encontrar el modelo?
 - *Ideal cuando un FN es inaceptable.*

Comandos Base: Regresión Logística (Scikit-Learn)

- `LogisticRegression()`: *Instanciación*. Genera el objeto clasificador configurado para Regresión Logística.
- `StandardScaler()`: *Instanciación*. Genera el transformador para estandarizar datos, crucial en regresión logística.
- `confusion_matrix(y_test, y_pred)`: *Evaluación*. Calcula la matriz de confusión evaluando las predicciones contra los valores reales.
- `classification_report(y_test, y_pred)`: *Evaluación*. Genera un reporte detallado con las métricas de Precisión, Recall y F1-Score para ambas clases.

Fin de la Presentación Teórica

Transición al Laboratorio Práctico:

`04_Regresion_Logistica.ipynb`