

# Módulo 4: Aprendizaje Automático

## Clase 2: Preparación de Variables (Feature Engineering y Escalado)

Diplomado en Ciencia de Datos

17 de julio de 2026

# Objetivos de la Sesión

- Comprender el impacto de la calidad de los datos en el rendimiento algorítmico (*Garbage in, Garbage out*).
- Identificar y procesar valores atípicos (outliers) y nulos (NaN) mediante limpieza e imputación estadística.
- Transformar variables categóricas en estructuras numéricas matriciales (One-Hot Encoding).
- Aplicar técnicas de normalización y estandarización para la homogeneización de magnitudes métricas.

## Fundamento Teórico:

Los modelos matemáticos carecen de intuición para procesar o ignorar espacios vacíos en las matrices de entrada.

- **Eliminación (Drop):** Se remueven filas completas. Aplicable solo si la proporción de datos corruptos es marginal.
- **Imputación:** Se sustituye el valor nulo por un estadístico representativo (Media o Mediana) para preservar el tamaño muestral sin alterar significativamente la distribución subyacente.

- `df.isnull().sum()`: *Diagnóstico*. Cuantifica la suma total de valores nulos presentes por cada característica.
- `df.dropna()`: *Eliminación*. Filtra y destruye los registros que contienen al menos un valor NaN.
- `df.fillna(valor)`: *Imputación*. Reemplaza los campos vacíos con el valor especificado (ej. media aritmética o mediana).
- `df.describe()`: *Auditoría*. Despliega los parámetros de estadística descriptiva básica para la identificación de valores atípicos (outliers).

## Codificación de Variables Categóricas (One-Hot Encoding)

Los algoritmos exigen entradas numéricas estrictas. Las variables de texto (nominales) impiden el cálculo de funciones de coste o distancias.

- **Variables Dummy:** Se proyecta una columna nominal (con  $n$  categorías) hacia  $n$  columnas binarias independientes.
- El valor 1 señala la presencia de la característica, y 0 su ausencia, habilitando la evaluación matricial ortogonal.

- `pd.get_dummies(df['col'])`: *Transformación*. Convierte la serie categórica indicada en múltiples series binarias independientes.
- `pd.concat([df1, df2], axis=1)`: *Integración*. Concatena matrices a lo largo de un eje específico. `axis=1` asegura la anexión horizontal (adición de columnas).
- `df.drop(columns=['col'])`: *Limpieza estructural*. Elimina las columnas nominales originales que ya han sido codificadas, evitando errores de tipado durante el entrenamiento.

## El Problema de la Magnitud Nominal

Algoritmos iterativos y basados en distancias (SVM, k-NN) asignan mayor peso matemático a variables con rangos numéricos extensos.

- **Normalización Min-Max:** Comprime toda la distribución al intervalo continuo estricto  $[0, 1]$ .

$$V_{nuevo} = \frac{V - V_{min}}{V_{max} - V_{min}}$$

- **Estandarización (Z-Score):** Modifica la distribución para obtener una media  $\mu = 0$  y desviación estándar  $\sigma = 1$ .

$$Z = \frac{V - \mu}{\sigma}$$

# Comandos Base: Escalado (Scikit-Learn)

- `StandardScaler()`: *Instanciación*. Genera el objeto transformador configurado para estandarización Z-Score.
- `MinMaxScaler()`: *Instanciación*. Genera el objeto transformador configurado para normalización en el rango  $[0,1]$ .
- `scaler.fit_transform(X)`: *Aplicación matricial*.
  - `fit`: Calcula los parámetros estadísticos requeridos (media, varianza, o mínimos y máximos) de la matriz  $X$ .
  - `transform`: Aplica la ecuación matemática sobre cada elemento de  $X$  retornando la matriz escalada equivalente.

# Fin de la Presentación Teórica

Transición al Laboratorio Práctico:

`02_Preparacion_de_Variables.ipynb`