

Día 08: Aplicaciones Industriales y Mega-Pipelines

Diplomado en Ciencia de Datos

Ing. Luis Antonio Molina

Universidad San Francisco Xavier (USFX)

Módulo 4: Aprendizaje Automático


Objetivos de la Sesión

- 1. Comprender la metodología **CRISP-DM** estándar en la industria.
- 2. Identificar y prevenir el peligroso problema de la **Fuga de Datos (Data Leakage)**.
- 3. Construir un **Mega-Pipeline** escalable utilizando Scikit-Learn.
- 4. Realizar un análisis de impacto financiero a través de la **Matriz de Confusión**.

El Estándar Industrial: CRISP-DM

La metodología **Cross-Industry Standard Process for Data Mining** asegura que los proyectos de Inteligencia Artificial no fracasen en producción.

Metodología CRISP-DM



El Peligro Oculto: Data Leakage (Fuga de Datos)

Definición Fatal

Ocurre cuando el algoritmo accede a información del conjunto de pruebas (examen) durante la fase de entrenamiento.

¿Cómo sucede accidentalmente?


- Imputar valores nulos (promedio/mediana) usando **todo** el dataset.
- Escalar variables utilizando el mínimo y máximo de **todo** el dataset.

Consecuencia: El modelo reportará 99 % de exactitud en el laboratorio, pero fracasará catastróficamente el día que se lance a producción.

La Solución Definitiva: El Pipeline

Para evitar la Fuga de Datos, empaquetamos las instrucciones de limpieza y el algoritmo en una sola tubería blindada.

Arquitectura de un Mega-Pipeline



Evaluación Empresarial: Falsos Positivos vs Negativos

Las métricas de exactitud (*Accuracy*) son inútiles para la Junta Directiva. Todo debe traducirse a **Dólares (Costos y Riesgos)**.

Ejemplo Médico: Predicción de Cáncer

- **Falso Positivo (Susto):** Decirle a un paciente sano que tiene cáncer. Costo: Ansiedad y exámenes adicionales.
- **Falso Negativo (Tragedia):** Decirle a un paciente con cáncer que está sano. Costo: Pérdida de la vida.

Lección de Negocios: Los Data Scientists ajustan los Pipelines para minimizar el tipo de error que le cueste más caro a la empresa.